

INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
Licenciatura en Ciencia de Datos

MINERÍA DE DATOS

PRÁCTICA 1. DEFINICIÓN DEL PROYECTO
SEMESTRAL

**Inteligencia de demanda de los principales sistemas de transporte público
de la Ciudad de México**

Integrante	Rol 1	Rol 2
Navarrete Flores Yariel	Coordinador	Analista de datos
Nava Villar Eric	Ingeniero de datos	Arquitecto
Uribe Sánchez Edén	Machine Learning	Visualizador

Periodo: 2026-B

Unidad de aprendizaje: Minería de Datos

Fecha de constitución: 23 de septiembre de 2026

Tabla de Contenidos

Resumen ejecutivo.....	3
Objetivo de la práctica	3
Alcance de esta entrega frente al proyecto semestral	3
Autores y responsabilidades	4
Introducción.....	4
1. CRISP-DM - Comprensión del problema (Business Understanding)	5
1.1 Contexto y problema por resolver	5
1.2 Pregunta de minería e hipótesis de trabajo.....	5
1.3 Objetivos del proyecto	5
1.4 Interesados, criterios de éxito, restricciones y exclusiones.....	5
2. CRISP-DM - Comprensión de los datos (Data Understanding).....	6
2.1 Exploración del Portal de Datos Abiertos	6
2.2 Inventario inicial de los recursos seleccionados.....	6
2.3 Matriz de cumplimiento de los requisitos del punto 2.....	6
2.4 Dimensiones temáticas y diccionario operativo de variables	7
2.5 Contraste entre diccionarios publicados y archivos reales	7
2.6 Granularidad temporal y espacial/operativa	7
2.7 Estadística descriptiva inicial.....	8
2.8 Auditoría de calidad de datos	8
2.9 Decisiones de transformación: RAW -> CLEAN	9
3. Caso de estudio complementario con perfil poblacional.....	9
4. Justificación de la selección, alcance y conocimiento esperado	10
5. Análisis exploratorio básico en Tableau.....	11
5.1 Inciso 9.a - Distribución de la dimensión categórica principal.....	11
5.2 Inciso 9.b - Distribución temporal	12
5.3 Inciso 9.c - Valores atípicos, faltantes, duplicados e inconsistencias	14
5.4 Inciso 9.d - Procesamiento de los registros originales	14
5.5 Exploración complementaria del segundo recurso.....	15
6. Acta constitutiva del proyecto de datos.....	16
6.1 Objetivos.....	16
6.2 Contexto, productos y criterios de éxito	16
6.3 Componentes de software.....	17
6.4 Plan de trabajo CRISP-DM.....	17
6.5 Riesgos y contingencias.....	17
6.6 Aprobación y responsabilidades.....	18
7. Reporte del estado de los datos	18
7.1 Limitaciones y supuestos actuales	18
8. Conclusiones y valoración de factibilidad	19
9. Referencias y fuentes consultadas	20
Anexo A. Evidencia técnica de PostgreSQL y DBeaver	21

Resumen ejecutivo

Esta práctica documenta la primera iteración técnica del proyecto semestral "Inteligencia de demanda de los principales sistemas de transporte público de la Ciudad de México". La propuesta semestral busca integrar gradualmente información oficial de afluencia de Metro, Metrobús, RTP, Cablebús, Trolebús y Tren Ligero. El propósito no es limitarse a presentar conteos o gráficas aisladas, sino construir gradualmente una base histórica homologada, identificar patrones temporales y operativos y, en etapas posteriores, desarrollar modelos para clasificar o estimar niveles de demanda en los principales sistemas de transporte público de la Ciudad de México.

Para esta primera práctica se utilizó al STC Metro como caso inicial, con el propósito de validar de extremo a extremo el proceso de selección, carga, comprensión, auditoría, transformación y exploración de datos.

Se trabajó con los recursos Afluencia Diaria del Metro (Simple) y Afluencia Diaria del Metro (Desglosada). Ambos superan el volumen mínimo exigido, cubren más de un año y presentan granularidades distintas. Los archivos fueron preservados en una capa RAW, importados a PostgreSQL, auditados mediante consultas reproducibles, transformados a capas CLEAN sin eliminación de filas y explorados en Tableau. La auditoría identificó problemas reales de codificación de caracteres, valores de afluencia iguales a cero, outliers estadísticos y 31 colisiones de una clave candidata en el recurso simple.

Objetivo de la práctica

Desarrollar y documentar la propuesta preliminar del proyecto semestral mediante las etapas 1 y 2 de CRISP-DM, realizando un primer reconocimiento técnico de dos recursos abiertos, verificando su volumen, cobertura, granularidad, calidad y posibilidades de integración, y generando evidencia exploratoria reproducible en PostgreSQL y Tableau.

Alcance de esta entrega frente al proyecto semestral

Nivel	Incluido en Práctica 1	Pendiente para iteraciones posteriores
Práctica 1	Comprensión del problema; comprensión de datos; carga RAW; perfilado; auditoría; CLEAN; Tableau; factibilidad inicial.	Integración multisistema completa, modelo dimensional definitivo, minería y evaluación.
Proyecto semestral	Metro como primera iteración técnica y patrón de diseño.	Metrobús, RTP, Cablebús, Trolebús y Tren Ligero; OLAP; técnicas estadísticas; reglas de asociación; árboles; redes neuronales; evaluación y despliegue académico.

Autores y responsabilidades

Integrante	Roles	Responsabilidad operativa en esta práctica
Navarrete Flores Yariel	Coordinador / Analista de datos	Control de alcance, CRISP-DM, planteamiento, análisis exploratorio, interpretación, consolidación del reporte y coordinación de entregables.
Nava Villar Eric	Ingeniero de datos / Arquitecto	Descarga e importación, PostgreSQL, preservación RAW, auditoría de calidad, estructura de datos y construcción de capas CLEAN.
Uribe Sánchez Edén	Machine Learning / Visualizador	Visualizaciones en Tableau, comunicación gráfica, revisión de variables y preparación conceptual para modelado posterior.

Introducción

La movilidad cotidiana de la Ciudad de México depende de varios sistemas de transporte público cuyos datos se publican por organismos y con diferentes periodos, estructuras y niveles de detalle. Esta fragmentación representa un reto de integración: antes de construir modelos de minería de datos es necesario demostrar que las fuentes pueden comprenderse, auditarse, homologarse y documentarse de forma reproducible.

La propuesta semestral se orienta a construir una base histórica de demanda que permita analizar patrones temporales y operativos y, en etapas posteriores, desarrollar análisis OLAP y modelos descriptivos y predictivos. La presente práctica se concentra deliberadamente en Metro como primera iteración para reducir riesgo técnico y establecer un procedimiento replicable al resto de los sistemas.

1. CRISP-DM - Comprensión del problema (Business Understanding)

1.1 Contexto y problema por resolver

La información de afluencia de los principales sistemas de transporte público de la Ciudad de México se publica de manera separada y con estructuras, periodos y granularidades diferentes. Esta heterogeneidad dificulta construir una visión homogénea de la demanda y comparar patrones entre sistemas. Se requiere un proceso reproducible que permita seleccionar, auditar, homologar y almacenar datos históricos de afluencia antes de aplicar técnicas de minería. La primera iteración debe demostrar que el flujo puede ejecutarse de forma controlada sobre una fuente oficial y suficientemente grande.

1.2 Pregunta de minería e hipótesis de trabajo

¿Qué patrones temporales y operativos caracterizan la demanda de los principales sistemas de transporte público de la Ciudad de México y en qué medida dichos patrones pueden utilizarse para clasificar o estimar niveles de afluencia?

La demanda presenta patrones diferenciables por sistema, línea, día, mes y periodo del año, de modo que es posible identificar perfiles de comportamiento y, posteriormente, construir modelos capaces de clasificar o estimar niveles de afluencia a partir de información histórica.

1.3 Objetivos del proyecto

Analizar y modelar los patrones históricos de demanda de los principales sistemas de transporte público de la Ciudad de México mediante técnicas de minería de datos, integrando información oficial de afluencia para identificar comportamientos temporales y operativos y evaluar modelos descriptivos y predictivos.

1. Recolectar y documentar conjuntos oficiales de afluencia de los sistemas seleccionados.
2. Diseñar un proceso ETL reproducible para limpiar, homologar e integrar las fuentes.
3. Construir una base histórica y un modelo multidimensional para análisis OLAP.
4. Analizar estadísticamente evolución, distribución, variabilidad y observaciones atípicas.
5. Aplicar técnicas descriptivas y predictivas coherentes con la pregunta del proyecto.
6. Evaluar modelos mediante métricas apropiadas y analizar su interpretabilidad.
7. Comunicar hallazgos mediante Tableau/Metabase y productos reproducibles.

1.4 Interesados, criterios de éxito, restricciones y exclusiones

Elemento	Definición preliminar
Interesados	Equipo académico, docente de la unidad de aprendizaje y, conceptualmente, analistas de movilidad y responsables de planeación/operación.
Éxito de Práctica 1	Dos recursos con volumen requerido; carga exacta en DBMS; granularidad documentada; auditoría de calidad; capa CLEAN reproducible; exploración en Tableau; reporte con evidencia.
Éxito del proyecto semestral	Integración controlada de varios sistemas; base histórica; OLAP; técnicas de minería justificadas; evaluación e interpretación; entregables finales reproducibles.
Restricciones	Datos abiertos disponibles, diferencias de granularidad, periodos históricos no homogéneos, cambios de esquema y necesidad de autorización si se incorpora otra fuente.
Fuera de alcance por ahora	Ruteo en tiempo real, optimización operacional, predicción de retrasos, causalidad de cambios y recomendaciones personalizadas de viaje.

2. CRISP-DM - Comprensión de los datos (Data Understanding)

2.1 Exploración del Portal de Datos Abiertos

Se exploró el Portal de Datos Abiertos de la Ciudad de México, con énfasis en la categoría Movilidad y en recursos publicados por SEMOVI. Se confirmó la existencia de información de afluencia para Metro y de fuentes candidatas para Metrobús, RTP y el Servicio de Transportes Eléctricos. Para la primera iteración se seleccionaron dos recursos de Metro por su tamaño, historia y nivel de detalle.

2.2 Inventario inicial de los recursos seleccionados

Criterio	Metro simple	Metro desglosada
Registros exactos	1,180,920	1,192,230
Cobertura real	2010-01-01 a 2026-07-31	2021-01-01 a 2026-07-31
Columnas reales	fecha, anio, mes, linea, estacion, afluencia	fecha, mes, anio, linea, estacion, tipo_pago, afluencia
Granularidad	fecha - línea - estación	fecha - línea - estación - tipo_pago
Formato	CSV	CSV
Organización	SEMOVI / STC Metro	SEMOVI / STC Metro

2.3 Matriz de cumplimiento de los requisitos del punto 2

Requisito de la guía	Metro simple	Metro desglosada	Evidencia / justificación
a) Cobertura mínima de un año	Cumple	Cumple	Simple: 2010-01-01 a 2026-07-31. Desglosada: 2021-01-01 a 2026-07-31.
b) Año/mes o fecha derivable	Cumple	Cumple	Ambos contienen fecha, anio y mes; las variables temporales pueden derivarse directamente.
c) Dimensión espacial o información para obtenerla	Cumple por identificador derivable	Cumple por identificador derivable	La combinación línea-estación identifica un punto de la red. No incluye coordenadas ni alcaldía en el CSV; éstas pueden obtenerse mediante enlace con el catálogo oficial de ubicación de estaciones, si el docente autoriza incorporar esa fuente.
d) $99,999 < n < 4,000,000$ y conteo en DBMS	Cumple	Cumple	COUNT(*) en PostgreSQL: 1,180,920 y 1,192,230 registros, respectivamente.
e) Otra fuente requiere consulta al profesor	Cumple en esta entrega	Cumple en esta entrega	No se integró ninguna fuente adicional. Las fuentes espaciales y poblacionales se proponen, pero no se usan en los cálculos actuales.

2.4 Dimensiones temáticas y diccionario operativo de variables

Las dimensiones identificadas son temporal, operativa/espacial, demanda y, en el recurso desglosado, modalidad de acceso. Además de revisar los diccionarios publicados, se contrastó su contenido con el esquema real de los CSV importados.

Recurso	Variable	Tipo/rol analítico	Interpretación
Simple	fecha	Fecha / dimensión temporal	Día al que corresponde el registro.
Simple	anio	Entero / dimensión temporal	Año del registro; validado contra fecha.
Simple	mes	Texto / dimensión temporal	Mes reportado; contiene las 12 categorías esperadas.
Simple	linea	Texto / dimensión operativa	Línea del STC Metro; se homologaron variantes de codificación.
Simple	estacion	Texto / dimensión espacial-operativa	Estación del registro; permite vinculación posterior con ubicación.
Simple	afluencia	Entero / medida	Cantidad de accesos reportados para la combinación observada.
Desglosada	tipo_pago	Texto / dimensión temática	Medio de acceso: Prepago, Boleto o Gratuidad.
Desglosada	afluencia	Entero / medida	Afluencia asociada con el tipo de acceso para estación-día.

2.5 Contraste entre diccionarios publicados y archivos reales

Recurso	Diccionario publicado	CSV real	Hallazgo
Simple	fecha, día, mes, ano, linea, estacion, afluencia	fecha, anio, mes, linea, estacion, afluencia	El CSV real no incluye día y utiliza anio en lugar de ano.
Desglosada	fecha, ano, mes, linea, afluencia_boleto, afluencia_prepago, afluencia_gratuidad, afluencia_total	fecha, mes, anio, linea, estacion, tipo_pago, afluencia	El diccionario describe formato ancho; el CSV real está en formato largo e incorpora estacion y tipo_pago.

2.6 Granularidad temporal y espacial/operativa

Granularidad temporal. Ambos recursos son diarios. Aunque incluyen las columnas anio y mes, la fecha conserva el nivel de día y permite derivar día de semana, mes numérico y fin de semana.

Granularidad del recurso simple. La unidad esperada es fecha-línea-estación. Durante la auditoría se encontraron 31 combinaciones repetidas de esa clave candidata, todas en Oceanía, Línea B, durante diciembre de 2020. Las filas no son duplicados exactos, porque contienen valores diferentes de afluencia.

Granularidad del recurso desglosado. La unidad es fecha-línea-estación-tipo_pago. No se observaron colisiones bajo esa clave candidata completa.

Dimensión espacial. La estación funciona como identificador de localización dentro de la red, pero los CSV analizados no incorporan latitud, longitud ni alcaldía. Esas variables pueden derivarse mediante una unión posterior por línea-estación con el catálogo oficial de geolocalización, sujeto a autorización docente si se incorpora como fuente.

2.7 Estadística descriptiva inicial

Estadístico	Metro simple	Metro desglosada
Registros	1,180,920	1,192,230
Afluencia mínima	0	0
Q1	7,462	16
Media	19,607.69	5,102.57
Q3	25,347	6,022
Afluencia máxima	263,056	119,577
Afluencia = 0	62,025 (5.25 %)	291,457 (24.45 %)
Outliers por IQR	66,361 (5.62 %)	103,485 (8.68 %)

El mayor porcentaje de ceros en el recurso desglosado es compatible con su mayor granularidad: una estación puede registrar demanda total durante un día y, al mismo tiempo, valor cero para una modalidad específica de acceso. Por esa razón los ceros no se eliminaron de forma automática.

2.8 Auditoría de calidad de datos

Regla	Metro simple	Metro desglosada	Decisión
Nulos	0	0	Sin imputación.
Afluencia negativa	0	0	No requiere corrección.
Duplicados exactos	0	0	No se eliminan filas.
Colisión de clave	31 grupos / 62 filas	0	Conservar y marcar; excluir temporalmente de algunas visualizaciones generales.
Estaciones con mojibake	57 nombres / 379,245 registros	57 nombres / 378,333 registros	Corregir representación de caracteres en CLEAN.
Líneas con mojibake	12 variantes / 171,795 registros	12 variantes / 515,385 registros	Homologar a las 12 líneas reales.
Consistencia año-fecha	0 inconsistencias	0 inconsistencias	Sin corrección.
Outliers IQR	66,361	103,485	Conservar y marcar: atípico no implica error.

2.9 Decisiones de transformación: RAW -> CLEAN

Hallazgo	Transformación aplicada	Justificación
Mojibake en línea/estación	Corrección de codificación y homologación de nombres.	Evitar categorías artificialmente duplicadas en agregaciones y Tableau.
Ceros	Se conservan; se crea bandera es_afluencia_cero.	Pueden representar condiciones válidas; no hay evidencia para tratarlos como error.
Outliers IQR	Se conservan; se crea bandera es_outlier_iqr.	Las estaciones poseen demandas muy diferentes; un valor alto puede ser real.
Colisión fecha-línea-estación	Se conservan las 62 filas; se crea bandera es_colision_clave.	No existe evidencia suficiente para decidir si sumar, reemplazar o eliminar.
Variables temporales	Se derivan mes_num, dia_semana_num, dia_semana y es_fin_semana.	Facilitar orden cronológico, segmentación y análisis posterior.

3. Caso de estudio complementario con perfil poblacional

La guía solicita proponer una forma de complementar al menos uno de los conjuntos seleccionados con información del perfil poblacional de la Ciudad de México. Para mantener el control de alcance, esta integración se formula como caso de estudio y no se ejecuta en la presente práctica.

Elemento	Propuesta
Pregunta complementaria	¿Las estaciones localizadas en zonas con mayor población residente o densidad presentan patrones de afluencia diferentes?
Unidad de integración	Estación del Metro -> alcaldía o AGEB mediante un catálogo geográfico oficial.
Variables poblacionales candidatas	Población total, densidad, grupos de edad y población económicamente activa, según disponibilidad de la fuente autorizada.
Variables de movilidad	Afluencia diaria/promedio, variabilidad, estacionalidad y clasificación futura de demanda.
Análisis posible	Comparaciones normalizadas, agrupamiento de estaciones y evaluación de relaciones estadísticas; sin asumir causalidad.
Condición de uso	No incorporar la fuente poblacional ni geográfica al análisis actual sin consultar previamente al profesor.

4. Justificación de la selección, alcance y conocimiento esperado

- Relevancia: la afluencia constituye una medida directa de la demanda observada del sistema.
- Disponibilidad: los recursos son públicos, oficiales y descargables en CSV desde el Portal de Datos Abiertos de la CDMX.
- Cobertura: la versión simple ofrece historia desde 2010 y la desglosada mayor detalle desde 2021.
- Volumen: ambos recursos cumplen el intervalo exigido y son suficientemente grandes para justificar un DBMS.
- Granularidad: fecha, línea, estación y tipo de pago permiten explorar dimensiones temporales, operativas y temáticas.
- Escalabilidad: el procedimiento RAW -> auditoría -> CLEAN -> Tableau puede replicarse al incorporar otros sistemas.

Alcance preliminar del semestre. Construir una base histórica homologada de afluencia de los principales sistemas públicos con información oficial disponible. Metro funciona como primera iteración; después se evaluará Metrobús, RTP, Cablebús, Trolebús y Tren Ligero usando una ventana temporal común cuando sea necesario.

Conocimiento esperado. Identificar patrones temporales de demanda, diferencias entre líneas/estaciones, cambios estructurales, perfiles de acceso y observaciones atípicas; posteriormente, preparar variables para reglas de asociación, árboles de decisión y redes neuronales.

5. Análisis exploratorio básico en Tableau

Las visualizaciones se construyeron sobre las capas CLEAN. Para los análisis generales del recurso simple se aplicó `es_colision_clave = False`, lo que excluye temporalmente 62 filas de granularidad ambigua sin borrarlas de PostgreSQL. Los outliers y los ceros permanecieron en el análisis.

5.1 Inciso 9.a - Distribución de la dimensión categórica principal




Figura 1. Afluencia total por línea del Metro de la Ciudad de México, 2025. Fuente: elaboración propia en Tableau con datos oficiales de SEMOVI.

La Línea 2 registró la mayor afluencia acumulada de 2025 con 217,004,388 accesos, seguida por la Línea 3 con 175,062,148 y la Línea B con 125,318,668. En el extremo inferior se ubicaron la Línea 4 con 25,097,593, la Línea 6 con 38,836,291 y la Línea 5 con 56,744,197. La gráfica describe concentración de demanda por línea; no mide eficiencia, pues las líneas difieren en estaciones, cobertura y condiciones operativas.

5.2 Inciso 9.b - Distribución temporal

Los datos poseen granularidad diaria; sin embargo, para analizar el comportamiento histórico del sistema se utilizaron dos niveles de agregación temporal: anual y mensual. La agregación anual permite identificar cambios estructurales de largo plazo, mientras que la mensual permite observar fluctuaciones dentro de cada año. El nivel diario se conserva en los datos originales para análisis posteriores, pero no se representa para todo el periodo debido a la alta densidad de observaciones.




Figura 2A. Evolución anual de la afluencia del Metro de la Ciudad de México, 2010-2025. Fuente: elaboración propia en Tableau con datos oficiales de SEMOVI.

Entre 2010 y 2019 la afluencia anual del Metro se mantuvo relativamente estable en un intervalo aproximado de 1.53 a 1.68 mil millones de accesos. El mayor valor del periodo previo a 2020 se observa en 2013, con **1,684,936,618 accesos**. Posteriormente se presenta una reducción importante: en 2020 la afluencia disminuye a **893,841,146 accesos** y en 2021 alcanza el mínimo del periodo analizado, con **794,299,549**. A partir de 2022 se observa una recuperación sostenida, pasando de **1,030,108,295 accesos** en 2022 a **1,255,370,592** en 2025. No obstante, el nivel de 2025 todavía permanece por debajo de los valores observados antes de 2020. La gráfica permite identificar un cambio estructural y una posterior recuperación de la demanda, aunque por sí sola no permite atribuir causalidad a dichos cambios.



Figura 2B. Evolución mensual de la afluencia del Metro de la Ciudad de México, 2010-2025. Fuente: elaboración propia en Tableau con datos oficiales de SEMOVI.

Entre 2010 y 2019 la serie mensual se mantiene en niveles relativamente altos, con fluctuaciones recurrentes. El máximo mensual del periodo analizado se registró en octubre de 2013 con **154,718,101 accesos**. A partir de 2020 se observa una ruptura marcada: mayo de 2020 presenta el mínimo con **35,899,769 accesos**. Posteriormente se identifica una recuperación progresiva entre 2021 y 2025. La visualización evidencia cambio temporal, pero no demuestra por sí sola su causa.

5.3 Inciso 9.c - Valores atípicos, faltantes, duplicados e inconsistencias




Figura 3. Principales hallazgos de calidad en la afluencia simple del Metro. Fuente: elaboración propia en Tableau a partir de la auditoría en PostgreSQL.

La auditoría identificó 66,361 observaciones potencialmente atípicas por IQR, 62,025 registros con afluencia igual a cero y 62 filas involucradas en 31 colisiones de la clave candidata. No se encontraron nulos, afluencias negativas ni duplicados exactos. Adicionalmente, el contraste con el diccionario y con las categorías reales evidenció mojibake en línea y estación y diferencias entre el esquema documentado y el CSV real. Los outliers y ceros se conservaron por no existir evidencia suficiente para considerarlos errores.

5.4 Inciso 9.d - Procesamiento de los registros originales




Figura 4. Registros conservados durante la preparación de datos. Fuente: elaboración propia en Tableau con resumen generado en PostgreSQL.

Los 1,180,920 registros originales de Metro simple se conservaron en la capa CLEAN. Para las visualizaciones generales se excluyeron temporalmente 62 registros con colisión de la clave candidata, quedando 1,180,858 registros en la capa analítica. La diferencia es un filtro de análisis, no una eliminación: las 62 filas permanecen en la base y pueden revisarse posteriormente.

5.5 Exploración complementaria del segundo recurso



Figura 5. Afluencia total por tipo de acceso al Metro de la Ciudad de México, 2025. Fuente: elaboración propia en Tableau con el recurso desglosado.

En 2025 el recurso desglosado registra 1,022,336,985 accesos clasificados como Prepago (81.44 %) y 233,033,607 como Gratuidad (18.56 %). Boleto registra 0 accesos en ese año dentro del recurso analizado. Esta observación describe el dataset; no debe transformarse, sin evidencia adicional, en una conclusión institucional sobre la desaparición del boleto físico.

6. Acta constitutiva del proyecto de datos

Elemento	Definición
Nombre del proyecto	Inteligencia de demanda de los principales sistemas de transporte público de la Ciudad de México
Institución	Instituto Politécnico Nacional - ESCOM - Licenciatura en Ciencia de Datos
Unidad de aprendizaje	Minería de Datos
Periodo	2026-B
Fecha de constitución	23 de septiembre de 2026
Duración	Semestre 2026-B
Equipo	Navarrete Flores Yariel, Nava Villar Eric y Uribe Sánchez Edén
Patrocinio/financiamiento	Proyecto académico; sin financiamiento externo declarado.

6.1 Objetivos

El objetivo general y los objetivos específicos corresponden a los establecidos en la sección 1.3 de este reporte. El propósito de esta acta es fijar el alcance inicial, responsables, productos, criterios de éxito y riesgos para controlar las iteraciones del proyecto.

Los objetivos técnicos de minería de datos son caracterizar perfiles de demanda, identificar asociaciones temporales y operativas, construir posteriormente modelos de clasificación o estimación mediante árboles de decisión y redes neuronales, y evaluar tanto su desempeño como su interpretabilidad.

6.2 Contexto, productos y criterios de éxito

Componente	Definición
Problema por resolver	Heterogeneidad de fuentes, periodos y granularidades que dificulta analizar de forma integrada la demanda.
Productos del semestre	Datos originales; código ETL y modelo; base histórica/analítica; tablero; presentación; reporte; exposición grabada.
Criterio de éxito de datos	Trazabilidad RAW -> CLEAN, calidad documentada, transformaciones reproducibles y granularidad explícita.
Criterio de éxito analítico	Patrones interpretables y modelos evaluados con métricas apropiadas, sin forzar técnicas que no correspondan al problema.
Criterio de éxito académico	Capaz de justificar procedencia, decisiones de limpieza, integración, modelado, evaluación y limitaciones.

6.3 Componentes de software

Componente	Uso
PostgreSQL + DBeaver	Carga RAW, auditoría, conteos exactos, CLEAN, índices y trazabilidad.
Tableau	Exploración visual, validación de patrones y comunicación de resultados.
Python / pandas	Automatización del ETL, análisis estadístico y preparación de variables en iteraciones posteriores.
scikit-learn	Árboles, redes y modelos complementarios cuando se alcance la fase de modelado.
PySpark	Escalabilidad sólo si el volumen y la práctica posterior justifican procesamiento distribuido.

6.4 Plan de trabajo CRISP-DM

Etapas	Actividad	Estado al cierre de Práctica 1
1. Comprensión del negocio	Problema, alcance, pregunta, hipótesis, interesados y criterios de éxito.	Avanzada
2. Comprensión de los datos	Inventario, diccionarios, granularidad, calidad, volumen y Tableau.	Avanzada
3. Preparación	ETL, homologación, integración y variables derivadas.	Iniciada con capas CLEAN
4. Modelado	Estadística, asociación, árboles, redes y modelos complementarios.	Pendiente
5. Evaluación	Validación, métricas, comparación e interpretación.	Pendiente
6. Despliegue	Base histórica, tablero, reporte, presentación y video.	Pendiente

6.5 Riesgos y contingencias

Riesgo	Impacto	Mitigación
Granularidades distintas entre sistemas	Comparaciones incorrectas	Definir una granularidad común para comparación y conservar detalle adicional en tablas específicas.
Periodos históricos diferentes	Sesgo temporal	Usar ventanas comunes para análisis multisistema y conservar históricos particulares por separado.
Cambios de esquema/documentación	ETL inestable o interpretación errónea	Versionar archivos, diccionarios, fecha de descarga y reglas de transformación.
Nulos, duplicados, mojibake y categorías inconsistentes	Resultados sesgados	Aplicar auditoría, reglas de calidad y trazabilidad RAW -> CLEAN.
Alcance excesivo	Proyecto inconcluso	Incorporación por iteraciones: Metro primero; demás sistemas después.

6.6 Aprobación y responsabilidades

Nombre	Cargo / roles	Firma	Fecha
Navarrete Flores Yariel	Coordinador / Analista de datos	Yariel Navarrete Flores	23/09/2026
Nava Villar Eric	Ingeniero de datos / Arquitecto	Eric Nava Villar	23/09/2026
Uribe Sánchez Edén	ML / Visualizador	Edén Uribe Sánchez	23/09/2026

7. Reporte del estado de los datos

La carga en PostgreSQL permitió documentar el volumen exacto y conservar una capa RAW sin modificaciones. Las capas CLEAN corrigen problemas de representación y agregan variables/banderas de control, pero no borran filas. Esta separación mantiene trazabilidad entre el dato descargado, el dato transformado y la versión usada para visualización.

Estado	Resultado
Volumen	Simple: 1,180,920 filas. Desglosada: 1,192,230 filas.
Cobertura	Simple: 2010-01-01 a 2026-07-31. Desglosada: 2021-01-01 a 2026-07-31.
Compleitud	0 valores nulos en los campos auditados.
Unicidad	0 duplicados exactos. Simple presenta 31 colisiones de clave / 62 filas.
Validez	0 afluencias negativas; ceros conservados y documentados.
Consistencia textual	Mojibake corregido en CLEAN; 12 líneas homologadas.
Atipicidad	66,361 outliers IQR en simple y 103,485 en desglosada; se conservan con bandera.
Trazabilidad	RAW intacto; CLEAN reproducible mediante SQL; Tableau conectado a CLEAN.

7.1 Limitaciones y supuestos actuales

- Los CSV no incluyen alcaldía ni coordenadas; la estación permite una vinculación posterior con el catálogo oficial de geolocalización, pero esa fuente no se integró en esta práctica.
- Los diccionarios publicados no reflejan exactamente el esquema real de los archivos descargados.
- Las cifras históricas de datos abiertos pueden recibir actualizaciones retroactivas.
- Los outliers estadísticos y los valores cero no se consideran automáticamente errores.
- La asociación temporal observada en Tableau no demuestra causalidad.
- Los años de inicio difieren entre recursos y, en el proyecto multisistema, será necesario utilizar ventanas temporales comparables.

8. Conclusiones y valoración de factibilidad

La propuesta es técnica y analíticamente viable como proyecto semestral. La primera iteración sobre Metro permitió probar el flujo completo de comprensión, carga, auditoría, transformación y exploración sin eliminar observaciones del dato original. Los dos recursos utilizados cumplen el rango de volumen requerido y poseen suficiente cobertura temporal para un diagnóstico inicial.

La etapa de comprensión de datos produjo hallazgos relevantes que justifican el preprocesamiento: no se detectaron nulos ni duplicados exactos, pero sí ceros, outliers, colisiones de clave y problemas sistemáticos de codificación. La creación de capas CLEAN evita alterar los datos originales y proporciona una base reproducible para las siguientes prácticas.

El análisis exploratorio mostró heterogeneidad de demanda entre líneas, una ruptura temporal importante alrededor de 2020 y recuperación posterior, además de una composición de acceso en 2025 dominada por Prepago. Estos resultados son descriptivos y no deben convertirse en afirmaciones causales sin evidencia adicional.

9. Referencias y fuentes consultadas

Portal de Datos Abiertos de la Ciudad de México. (2026). Portal de Datos Abiertos. <https://datos.cdmx.gob.mx/>

Secretaría de Movilidad. (2026). Afluencia diaria del Metro CDMX. Portal de Datos Abiertos de la Ciudad de México. <https://www.datos.cdmx.gob.mx/es/dataset/afluencia-diaria-del-metro-cdmx>

Secretaría de Movilidad. (2026). Ubicación de líneas y estaciones del Sistema de Transporte Colectivo Metro. Portal de Datos Abiertos de la Ciudad de México. <https://datos.cdmx.gob.mx/dataset/lineas-y-estaciones-del-metro>

Secretaría de Movilidad. (2026). Afluencia diaria de Metrobús CDMX. Portal de Datos Abiertos de la Ciudad de México. https://www.datos.cdmx.gob.mx/es_AR/dataset/afluencia-diaria-de-metrobus-cdmx

Secretaría de Movilidad. (2026). Afluencia diaria de la Red de Transporte de Pasajeros. Portal de Datos Abiertos de la Ciudad de México.

Secretaría de Movilidad. (2026). Afluencia diaria Servicio de Transportes Eléctricos. Portal de Datos Abiertos de la Ciudad de México.


IPN - ESCOM. (2026). Práctica 1. Definición del proyecto semestral. Unidad de aprendizaje Minería de Datos.

Anexo A. Evidencia técnica de PostgreSQL y DBeaver


Las siguientes evidencias documentan operaciones consideradas críticas en la guía: conteo exacto de registros, cobertura temporal, calidad y conservación de información durante la limpieza. Los archivos originales de captura deben conservarse en 06_Evidencias dentro del ZIP.

Evidencia de carga y cobertura en PostgreSQL


Conteo exacto - Metro simple



Conteo exacto - Metro desglosada



Cobertura temporal - Metro simple



Cobertura temporal - Metro desglosada




Figura A1. Evidencia de conteos exactos y coberturas temporales en PostgreSQL/DBeaver.

Evidencia de calidad: completitud y duplicados

Nulos - Metro simple

Script 2: `-- 4.3 Revisar valores nulos en Metro_simple`

```
SELECT
COUNT(*) AS total_registros,
COUNT(*) FILTER (WHERE fecha IS NULL) AS nulos_fecha,
COUNT(*) FILTER (WHERE anio IS NULL) AS nulos_anio,
COUNT(*) FILTER (WHERE mes IS NULL) AS nulos_mes,
COUNT(*) FILTER (WHERE linea IS NULL) AS nulos_linea,
COUNT(*) FILTER (WHERE estacion IS NULL) AS nulos_estacion,
COUNT(*) FILTER (WHERE tipo_pago IS NULL) AS nulos_tipo_pago,
COUNT(*) FILTER (WHERE afluencia IS NULL) AS nulos_afluencia
FROM practica01.metro_simple_raw;
```

Script 2: `-- 4.3 Revisar valores nulos en Metro_desglosada`

```
SELECT
COUNT(*) AS total_registros,
COUNT(*) FILTER (WHERE fecha IS NULL) AS nulos_fecha,
COUNT(*) FILTER (WHERE anio IS NULL) AS nulos_anio,
COUNT(*) FILTER (WHERE mes IS NULL) AS nulos_mes,
COUNT(*) FILTER (WHERE linea IS NULL) AS nulos_linea,
COUNT(*) FILTER (WHERE estacion IS NULL) AS nulos_estacion,
COUNT(*) FILTER (WHERE tipo_pago IS NULL) AS nulos_tipo_pago,
COUNT(*) FILTER (WHERE afluencia IS NULL) AS nulos_afluencia
FROM practica01.metro_desglosada_raw;
```

Script 2: `-- 4.3 Revisar afluencia cero y negativa para Metro_simple`

```
SELECT
COUNT(*) FILTER (WHERE afluencia = 0) AS afluencia_negativa,
COUNT(*) FILTER (WHERE afluencia < 0) AS afluencia_cero,
SUM(afluencia) AS afluencia_total;
```

total_registros	nulos_fecha	nulos_anio	nulos_mes	nulos_linea	nulos_estacion	nulos_tipo_pago	nulos_afluencia
1.180.900	0	0	0	0	0	0	0

Nulos - Metro desglosada

Script 2: `-- 4.3 Revisar valores nulos en Metro_desglosada`

```
SELECT
COUNT(*) AS total_registros,
COUNT(*) FILTER (WHERE fecha IS NULL) AS nulos_fecha,
COUNT(*) FILTER (WHERE anio IS NULL) AS nulos_anio,
COUNT(*) FILTER (WHERE mes IS NULL) AS nulos_mes,
COUNT(*) FILTER (WHERE linea IS NULL) AS nulos_linea,
COUNT(*) FILTER (WHERE estacion IS NULL) AS nulos_estacion,
COUNT(*) FILTER (WHERE tipo_pago IS NULL) AS nulos_tipo_pago,
COUNT(*) FILTER (WHERE afluencia IS NULL) AS nulos_afluencia
FROM practica01.metro_desglosada_raw;
```

Script 2: `-- 4.3 Revisar afluencia cero y negativa para Metro_simple`

```
SELECT
COUNT(*) FILTER (WHERE afluencia = 0) AS afluencia_negativa,
COUNT(*) FILTER (WHERE afluencia < 0) AS afluencia_cero,
SUM(afluencia) AS afluencia_total;
```

total_registros	nulos_fecha	nulos_anio	nulos_mes	nulos_linea	nulos_estacion	nulos_tipo_pago	nulos_afluencia
1.180.900	0	0	0	0	0	0	0

Duplicados exactos - Metro simple

Script 2: `-- 4.3 Buscar duplicados exactos en Metro_simple`

```
SELECT COUNT(*) AS duplicados_exactos
FROM (
SELECT
fecha,
anio,
mes,
linea,
estacion,
tipo_pago,
afluencia,
COUNT(*) AS veces
FROM practica01.metro_simple_raw
GROUP BY
fecha,
anio,
mes,
linea,
estacion,
tipo_pago,
afluencia
HAVING COUNT(*) > 1
) t;
```

duplicados_exactos
123

Duplicados exactos - Metro desglosada

Script 2: `-- Buscar duplicados exactos en Metro_desglosada`

```
SELECT COUNT(*) AS duplicados_exactos
FROM (
SELECT
fecha,
anio,
mes,
linea,
estacion,
tipo_pago,
afluencia,
COUNT(*) AS veces
FROM practica01.metro_desglosada_raw
GROUP BY
fecha,
anio,
mes,
linea,
estacion,
tipo_pago,
afluencia
HAVING COUNT(*) > 1
) t;
```

duplicados_exactos
123

Figura A2. Evidencia de completitud y ausencia de duplicados exactos.

Evidencia de inconsistencias y transformación RAW -> CLEAN

Colisiones de clave - Oceanía

mineria_datos_2026b <postgres> Script-2 X

-- 4.4 Buscar duplicados segun la granularidad esperada en Metro_simple

SELECT

metro_simple_raw 1 X

Enter a SQL expression to filter results (use Ctrl+Space)

Grid	fecha	AZ linea	AZ estacion	123 cantidad
4	2020-12-04	Linea B	OceanA-a	2
5	2020-12-05	Linea B	OceanA-a	2
6	2020-12-06	Linea B	OceanA-a	2
7	2020-12-07	Linea B	OceanA-a	2
8	2020-12-08	Linea B	OceanA-a	2
9	2020-12-09	Linea B	OceanA-a	2
10	2020-12-10	Linea B	OceanA-a	2
11	2020-12-11	Linea B	OceanA-a	2
12	2020-12-12	Linea B	OceanA-a	2
13	2020-12-13	Linea B	OceanA-a	2
14	2020-12-14	Linea B	OceanA-a	2
15	2020-12-15	Linea B	OceanA-a	2
16	2020-12-16	Linea B	OceanA-a	2
17	2020-12-17	Linea B	OceanA-a	2
18	2020-12-18	Linea B	OceanA-a	2
19	2020-12-19	Linea B	OceanA-a	2
20	2020-12-20	Linea B	OceanA-a	2
21	2020-12-21	Linea B	OceanA-a	2
22	2020-12-22	Linea B	OceanA-a	2
23	2020-12-23	Linea B	OceanA-a	2
24	2020-12-24	Linea B	OceanA-a	2
25	2020-12-25	Linea B	OceanA-a	2
26	2020-12-26	Linea B	OceanA-a	2
27	2020-12-27	Linea B	OceanA-a	2
28	2020-12-28	Linea B	OceanA-a	2
29	2020-12-29	Linea B	OceanA-a	2
30	2020-12-30	Linea B	OceanA-a	2
31	2020-12-31	Linea B	OceanA-a	2

Mojibake en categorías de línea

mineria_datos_2026b <postgres> Script-2 X

-- 4.7 Detectar textos posiblemente corruptos en Metro_simple

SELECT DISTINCT linea

FROM practica01.metro_simple_raw

WHERE linea LIKE '%A%';

metro_simple_raw 1 X metro_simple_raw 2

Enter a SQL expression to filter results

Grid	AZ linea
1	LÃ-nea 1
2	LÃ-nea 12
3	LÃ-nea 2
4	LÃ-nea 3
5	LÃ-nea 4
6	LÃ-nea 5
7	LÃ-nea 6
8	LÃ-nea 7
9	LÃ-nea 8
10	LÃ-nea 9
11	LÃ-nea A
12	LÃ-nea B

Conteo conservado en CLEAN

Conne... X Projects

mineria_datos_2026b <postgres> 03_limieza_tableau X

-- 6.5 Validamos que NO destruimos informacion

SELECT COUNT(*)

FROM practica01.metro_simple_clean;

SELECT COUNT(*)

FROM practica01.metro_desglosada_clean;

-- Debemos seguir teniendo:

metro_simple_clean 1 X metro_desglosada_clean 2

Enter a SQL expression to filter results

Grid	count
1	1,180,920

12 líneas homologadas en CLEAN

Conne... X Projects

mineria_datos_2026b <postgres> 03_limieza_tableau X

SELECT DISTINCT linea

FROM practica01.metro_simple_clean

ORDER BY linea;

-- Deberiamos tener 12 lineas, no 24.

metro_simple_clean 1 X

Enter a SQL expression to filter results

Grid	AZ linea
1	Linea 1
2	Linea 12
3	Linea 2
4	Linea 3
5	Linea 4
6	Linea 5
7	Linea 6
8	Linea 7
9	Linea 8
10	Linea 9
11	Linea A
12	Linea B

Figura A3. Evidencia de colisiones, mojobake y validación de la capa CLEAN.