



PRÁCTICA 2

Comprensión de datos, Ingesta, limpieza y EDA

Integrante	Roles
Navarrete Flores Yariel	Coordinador / Analista de datos
Nava Villar Eric	Ingeniero de datos / Arquitecto
Uribe Sánchez Edén	Machine Learning / Visualizador

Unidad de aprendizaje	Minería de Datos
Fecha	2 de octubre de 2026

Autores y responsabilidades

Nombre	Roles	Responsabilidad en la práctica
Navarrete Flores Yariel	Coordinador / Analista de datos	Integración del flujo, ejecución de referencia, control de Git/GitHub, validación de resultados y revisión del reporte.
Nava Villar Eric	Ingeniero de datos / Arquitecto	Diseño de STAGING, ingesta, estructura SQL, consolidación y soporte de reproducibilidad.
Uribe Sánchez Edén	Machine Learning / Visualizador	Perfilado, EDA, interpretación de calidad, tablas de resultados y apoyo a documentación.

Introducción

El propósito de esta práctica fue aplicar un proceso reproducible de ingesta, validación, limpieza y análisis exploratorio sobre datos reales de COVID-19, con énfasis en las etapas de comprensión y preparación de datos. La ejecución se realizó en PostgreSQL 18.3, utilizando Python para inspección y preparación de fuentes, psql para la carga con \copy, DBeaver para las consultas de validación y Git/GitHub para trazabilidad del trabajo del equipo.

Se trabajó con dos archivos históricos correspondientes a 2022 y 2023, además de los catálogos y descriptores proporcionados. La estrategia adoptada separó el proceso en capas: RAW (fuente original), WORKING (derivados reproducibles), STAGE (conservación de valores como texto), TYPED (tipado y limpieza controlada) e HISTÓRICA (homologación de ambos periodos). Esta separación permitió conservar evidencia de los valores originales y evitar pérdidas por conversiones prematuras.

El resultado final fue una tabla histórica de 2,099,997 registros, sin pérdida respecto de las fuentes válidas, sin ID_REGISTRO nulos o repetidos y con reglas de limpieza documentadas. El reporte cubre estrictamente los apartados obligatorios 1 a 6 y los entregables del apartado 8 de la guía; la pregunta opcional 7.1 no se incorpora en esta entrega.

Estrategia de trazabilidad: Las cifras reportadas como resultados fueron reproducidas en la máquina de referencia del coordinador. Los scripts completos se incluyen en el ZIP de entrega; en este documento se muestran únicamente fragmentos SQL relevantes y evidencia necesaria.

1. Preparación e inspección del conjunto de datos

1.1 Inventario de fuentes

Recurso	Capa / uso	Tamaño	Observación
muestra200k_COVID19MEXICOLOC2022.csv	RAW 2022	686,356,922 bytes (654.56 MiB)	Archivo recibido; se demostró duplicación física completa.
muestra100k_COVID19MEXICOLOC2023.csv	RAW 2023	20,258,324 bytes (19.32 MiB)	Fuente utilizada directamente después de la inspección.
201128 Catalogos.xlsx	Catálogos	-	Dominios y códigos de referencia.
201128 Descriptores.xlsx	Descriptor	-	Significado de variables; se contrastó contra los CSV reales.
Práctica 2 DM - Ingesta limpieza y EDA.pdf	Guía	-	Criterios técnicos y entregables de la práctica.

1.2 Inspección preliminar

Elemento	2022 (copia útil)	2023
Registros de datos	1,999,998	99,999
Columnas	41	44
Codificación	UTF-8 válida	UTF-8 válida
Delimitador de campos	Coma (,)	Coma (,)
Calificador de texto	Comillas dobles	Comillas dobles
Delimitador de filas	CRLF (\r\n)	CRLF (\r\n)

Elemento	2022 (copia útil)	2023
Formato de fechas	AAAA-MM-DD; FECHA_DEF usa 9999-99-99	AAAA-MM-DD; FECHA_DEF y FECHA_RESULTADO usan 9999-99-99
Cadenas vacías visibles	0	0
Filas malformadas en archivo utilizable	0	0

Los encabezados de 2022 están contenidos en el esquema 2023. En 2023 aparecen tres campos adicionales: MUNICIPIO_UM, CLUES y FECHA_RESULTADO. Por ello se utilizaron tablas STAGE separadas por versión y una homologación posterior.

2. Creación de la base de datos y de la tabla temporal

2.1 Base de datos de trabajo

Se utilizó PostgreSQL 18.3. La base covid20a23sedi se creó con UTF-8 para conservar correctamente caracteres acentuados y valores textuales internacionales.

```
CREATE DATABASE covid20a23sedi
  WITH ENCODING = 'UTF8'
  TEMPLATE = template0;
```

2.2 Tablas STAGE

La primera ingesta se realizó a tablas de etapa con columnas TEXT. Esta capa prioriza conservación: evita que centinelas de fecha, códigos, espacios o caracteres de control provoquen pérdida de filas antes de analizar su dominio.

Tabla	Columnas	Tipo en STAGE	Registros antes de ingesta
covid_stage_2022	41	TEXT	0
covid_stage_2023	44	TEXT	0

3. Ingesta de los archivos CSV

3.1 Carga mediante PostgreSQL / psql

La ingesta se ejecutó mediante psql y \copy. Antes de cada carga se vacían las tablas STAGE con TRUNCATE para que el script sea re-ejecutable sin duplicar registros.

```
\encoding UTF8
\set ON_ERROR_STOP on
TRUNCATE TABLE covid_stage_2022;
TRUNCATE TABLE covid_stage_2023;

\copy covid_stage_2022 FROM '.../muestra200k_COVID19MEXICOLOC2022_trabajo.csv' WITH (FORMAT csv, HEADER true, DELIMITER ',',
QUOTE '', ENCODING 'UTF8')
\copy covid_stage_2023 FROM '.../muestra100k_COVID19MEXICOLOC2023.csv' WITH (FORMAT csv, HEADER true, DELIMITER ',', QUOTE
'', ENCODING 'UTF8')
```

3.2 Parámetros utilizados

Parámetro	Función en la ingesta
FORMAT csv	Interpreta la sintaxis CSV y el uso de campos entre comillas.
HEADER true	Omite el encabezado como registro de datos.
DELIMITER ','	Define la coma como separador de campos.
QUOTE ""	Define comillas dobles como calificador de texto.
ENCODING 'UTF8'	Alinea la carga con la codificación verificada en las fuentes.
\copy	Lee los archivos desde la máquina cliente que ejecuta psql.
\encoding UTF8	Corrige la codificación del cliente antes de ejecutar el script.
ON_ERROR_STOP	Detiene el script ante un error para evitar continuar con un estado parcial.

3.3 Resultados y problema de ingesta

Resultado	2022	2023
COPY / filas cargadas	1,999,998	99,999

Durante la primera ejecución se presentó un error de codificación: psql inició con client_encoding = WIN1252 y el script estaba guardado en UTF-8. El error se corrigió estableciendo \encoding UTF8; después de la corrección, SHOW client_encoding devolvió UTF8 y ambas cargas finalizaron correctamente. No fue necesario modificar los CSV.

Problema	Evidencia	Causa	Solución	Verificación
ING-001 - Codificación del cliente	Byte 0x81 interpretado bajo WIN1252	client_encoding distinto al formato del script	\encoding UTF8 al inicio de 02_ingesta.sql	COPY 1999998 y COPY 99999 sin errores

4. Refinamiento de tipos y limpieza inicial

4.1 Perfilado previo a la conversión

Antes de ejecutar CAST se comprobaron sintácticamente todas las fechas y todas las columnas destinadas a SMALLINT. PostgreSQL no detectó valores no convertibles después de aplicar BTRIM. Los rangos de EDAD fueron 0-122 en 2022 y 0-113 en 2023.

Control	2022	2023	Resultado
Fechas inválidas adicionales	0	0	Conversión segura a DATE
Campos numéricos no convertibles	0 en todas las columnas	0 en todas las columnas	Conversión segura a SMALLINT
Rango EDAD	0 a 122	0 a 113	Compatible con SMALLINT
Longitud ID_REGISTRO	máx. 7	máx. 7	VARCHAR(7)
Longitud CLUES	N/A	máx. 11	VARCHAR(11)
Longitud PAIS_NACIONALIDAD	máx. 54	máx. 36	VARCHAR(60)
Longitud PAIS_ORIGEN	máx. 54	máx. 25	VARCHAR(60)

4.2 Reglas de limpieza justificadas

Regla	Evidencia	Transformación	Conservación de evidencia
Fechas centinela	9999-99-99 en FECHA_DEF y FECHA_RESULTADO	CASE -> NULL en tablas tipadas	Valor original permanece en STAGE
MIGRANTE con TAB	ID_REGISTRO 15ec76 contiene <TAB>99	BTRIM(..., E' \t\r\n') antes del cast	STAGE conserva el texto original
Códigos 97/98/99	Dominios de catálogo	Se conservan como categorías; no se convierten automáticamente a NULL	STAGE y TYPED permiten rastreo
Cambio de esquema	41 vs 44 columnas	Tablas tipadas por año y homologación explícita	Se registra año y archivo fuente en HISTÓRICA

4.3 Mapa de tipos final

Campo	Presencia	Tipo final	Justificación
FECHA_ACTUALIZACION	2022/2023	DATE	Fecha ISO válida
ID_REGISTRO	2022/2023	VARCHAR(7)	Identificador alfanumérico
ORIGEN	2022/2023	SMALLINT	Código de catálogo
SECTOR	2022/2023	SMALLINT	Código de catálogo
ENTIDAD_UM	2022/2023	SMALLINT	Código de entidad
MUNICIPIO_UM	2023	SMALLINT	Código municipal de la unidad
CLUES	2023	VARCHAR(11)	Identificador alfanumérico
SEXO	2022/2023	SMALLINT	Código de catálogo
ENTIDAD_NAC	2022/2023	SMALLINT	Código de entidad
ENTIDAD_RES	2022/2023	SMALLINT	Código de entidad
MUNICIPIO_RES	2022/2023	SMALLINT	Código municipal
LOCALIDAD_RES	2022/2023	SMALLINT	Código de localidad
TIPO_PACIENTE	2022/2023	SMALLINT	Código categórico
FECHA_INGRESO	2022/2023	DATE	Fecha ISO válida
FECHA_SINTOMAS	2022/2023	DATE	Fecha ISO válida
FECHA_DEF	2022/2023	DATE NULL	9999-99-99 -> NULL
INTUBADO	2022/2023	SMALLINT	Código categórico
NEUMONIA	2022/2023	SMALLINT	Código categórico
EDAD	2022/2023	SMALLINT	Variable cuantitativa
NACIONALIDAD	2022/2023	SMALLINT	Código de catálogo
EMBARAZO	2022/2023	SMALLINT	Código categórico
HABLA_LENGUA_INDIG	2022/2023	SMALLINT	Código categórico
INDIGENA	2022/2023	SMALLINT	Código categórico
DIABETES	2022/2023	SMALLINT	Código categórico
EPOC	2022/2023	SMALLINT	Código categórico
ASMA	2022/2023	SMALLINT	Código categórico
INMUSUPR	2022/2023	SMALLINT	Código categórico
HIPERTENSION	2022/2023	SMALLINT	Código categórico
OTRA_COM	2022/2023	SMALLINT	Código categórico
CARDIOVASCULAR	2022/2023	SMALLINT	Código categórico
OBESIDAD	2022/2023	SMALLINT	Código categórico
RENAL_CRONICA	2022/2023	SMALLINT	Código categórico
TABAQUISMO	2022/2023	SMALLINT	Código categórico
OTRO_CASO	2022/2023	SMALLINT	Código categórico
TOMA_MUESTRA_LAB	2022/2023	SMALLINT	Código categórico
RESULTADO_LAB	2022/2023	SMALLINT	Código de resultado
TOMA_MUESTRA_ANTIGENO	2022/2023	SMALLINT	Código categórico
RESULTADO_ANTIGENO	2022/2023	SMALLINT	Código de resultado
CLASIFICACION_FINAL	2022/2023	SMALLINT	Código de clasificación
FECHA_RESULTADO	2023	DATE NULL	9999-99-99 -> NULL
MIGRANTE	2022/2023	SMALLINT	BTRIM antes del cast
PAIS_NACIONALIDAD	2022/2023	VARCHAR(60)	Nombre textual de país
PAIS_ORIGEN	2022/2023	VARCHAR(60)	Texto mixto / valor 97
UCI	2022/2023	SMALLINT	Código categórico

4.4 Verificación STAGE -> TYPED

Capa	2022	2023	Diferencia
STAGE	1,999,998	99,999	-
TYPED	1,999,998	99,999	0 registros perdidos
Campo / control		Resultado	
FECHA_DEF NULL - 2022		1,983,215	
FECHA_DEF NULL - 2023		99,223	
FECHA_RESULTADO NULL - 2023		82,283	
MIGRANTE 15ec76		<TAB>99 en STAGE -> 99 en TYPED	

```
-- VALIDACIÓN INICIAL
-- =====
SELECT
  '2022 stage' AS tabla,
  COUNT(*) AS registros
FROM covid_stage_2022

UNION ALL

SELECT
  '2022 tipada',
  COUNT(*)
FROM covid_2022_tipada

UNION ALL

SELECT
  '2023 stage',
  COUNT(*)
FROM covid_stage_2023

UNION ALL

SELECT
  '2023 tipada',
  COUNT(*)
FROM covid_2023_tipada;
```

Conteos STAGE y TYPED coincidentes.

```
SELECT
  s.id_registro,
  REGEXP_REPLACE(
    s.migrante,
    E'\t',
    '<TAB>',
    'g'
  ) AS stage_original_visible,
  t.migrante AS valor_tipado
FROM covid_stage_2022 AS s
JOIN covid_2022_tipada AS t
  ON s.id_registro = t.id_registro
WHERE s.id_registro = '15ec76';
```

Normalización de MIGRANTE: <TAB>99 -> 99.

5. Consolidación de la tabla histórica

5.1 Homologación de los periodos

Se creó covid_historica con el superset de las 44 variables observadas en 2023 y dos metadatos de trazabilidad: anio_fuente y archivo_fuente. Para 2022, MUNICIPIO_UM, CLUES y FECHA_RESULTADO se asignaron como NULL estructurales porque esas variables no existen en la fuente 2022.

```
INSERT INTO covid_historica (...)
SELECT ..., NULL::smallint AS municipio_um, NULL::varchar(11) AS clues, ..., NULL::date AS fecha_resultado, ..., 2022 AS anio_fuente,
'muestra200k_COVID19MEXICOLOC2022_trabajo.csv' AS archivo_fuente
FROM covid_2022_tipada;

INSERT INTO covid_historica (...)
SELECT ..., 2023 AS anio_fuente, 'muestra100k_COVID19MEXICOLOC2023.csv' AS archivo_fuente
FROM covid_2023_tipada;
```

5.2 Conciliación de registros

Origen	Registros
2022 tipada	1,999,998
2023 tipada	99,999
Suma de fuentes	2,099,997
covid_historica	2,099,997
Diferencia	0

5.3 Auditoría de duplicados

Control	Resultado
Total de registros	2,099,997
ID_REGISTRO NULL	0
ID_REGISTRO distintos	2,099,997
ID_REGISTRO repetidos	0
Repetidos dentro de 2022	0
Repetidos dentro de 2023	0
Presentes en ambos años	0
Grupos ID_REGISTRO + FECHA_ACTUALIZACION repetidos	0
Duplicados exactos	0

Criterio de decisión: no se eliminó ningún registro porque la auditoría no detectó duplicados. La tabla histórica conserva los 2,099,997 registros válidos de origen.

6. Análisis exploratorio y calidad de los datos

6.1 PAIS_NACIONALIDAD y campos asociados

Métrica	PAIS_NACIONALIDAD	NACIONALIDAD	PAIS_ORIGEN
Mínimo	Afganistán	1	97
Máximo	Zona Neutral	2	Yemen Democrática
Valores distintos	152	2	94

En los campos textuales, MIN y MAX son resultados lexicográficos y no representan una magnitud. El catálogo define NACIONALIDAD = 1 como MEXICANA y 2 como EXTRANJERA; en la muestra no apareció el código 99 para esta variable.

PAIS_NACIONALIDAD	Frecuencia	Porcentaje
México	2,072,816	98.7057 %
Estados Unidos de América	14,167	0.6746 %
Nicaragua	1,287	0.0613 %
Colombia	1,034	0.0492 %
Venezuela	986	0.0470 %
Ucrania	773	0.0368 %
China	727	0.0346 %
Otro	697	0.0332 %
República de Honduras	642	0.0306 %
Canadá	634	0.0302 %
NACIONALIDAD	Frecuencia	
1 - Mexicana	2,072,816	
2 - Extranjera	27,181	

La comprobación de coherencia entre NACIONALIDAD y PAIS_NACIONALIDAD no encontró casos donde nacionalidad = 1 tuviera un país distinto de México ni casos donde nacionalidad = 2 tuviera PAIS_NACIONALIDAD = México bajo la regla analizada.

frecuencias principales de PAIS_NACIONALIDAD.

6.2 MUNICIPIO_RES, ENTIDAD_RES y anomalías de catálogo

Métrica	Resultado
MUNICIPIO_RES mínimo	1
MUNICIPIO_RES máximo	999
Valores distintos de MUNICIPIO_RES	509
ENTIDAD_RES mínimo	1
ENTIDAD_RES máximo	32
Entidades distintas	32
Combinaciones distintas ENTIDAD_RES + MUNICIPIO_RES	2,369

MUNICIPIO_RES no debe interpretarse de manera aislada, porque el mismo código municipal puede existir en entidades diferentes. Por ello, la unidad territorial utilizada en la auditoría fue la combinación ENTIDAD_RES + MUNICIPIO_RES.

ENTIDAD_RES	Registros con MUNICIPIO_RES = 999
08	4
09	4
19	2
21	2
05	2
02	2
17	1
24	1
31	1
01	1
32	1
03	1
04	1
07	1
11	1
16	1

Se observaron 26 registros con MUNICIPIO_RES = 999 dentro de entidades 1-32. El catálogo define 999 como NO ESPECIFICADO para municipio; por lo tanto, estos casos se conservan y no se tratan como errores. No se observaron las combinaciones especiales 97/997, 98/998 o 99/999 en esta muestra, ni combinaciones especiales inconsistentes.

	123 entidad_res	123 municipio_no_especificado
1	8	4
2	9	4
3	19	2
4	21	2
5	5	2
6	2	2
7	17	1
8	24	1
9	31	1
10	1	1
11	32	1
12	3	1
13	4	1
14	7	1
15	11	1
16	16	1

Registros con municipio 999 (NO ESPECIFICADO).

SELECT nacionalidad, pais_i Enter a SQL expression to filter results (use ▶ ▼)				
Grid	123 nacionalidad	AZ pais_nacionalidad	123 frecuencia	
Text				

La consulta de inconsistencias NACIONALIDAD - PAIS_NACIONALIDAD devuelve 0 filas.

6.3 Valores NULL de todas las columnas

Columna	NULL	Total	Porcentaje NULL
fecha_actualizacion	0	2,099,997	0.0000 %
id_registro	0	2,099,997	0.0000 %
origen	0	2,099,997	0.0000 %
sector	0	2,099,997	0.0000 %
entidad_um	0	2,099,997	0.0000 %
municipio_um	1,999,998	2,099,997	95.2381 %
clues	1,999,998	2,099,997	95.2381 %

Columna	NULL	Total	Porcentaje NULL
sexo	0	2,099,997	0.0000 %
entidad_nac	0	2,099,997	0.0000 %
entidad_res	0	2,099,997	0.0000 %
municipio_res	0	2,099,997	0.0000 %
localidad_res	0	2,099,997	0.0000 %
tipo_paciente	0	2,099,997	0.0000 %
fecha_ingreso	0	2,099,997	0.0000 %
fecha_sintomas	0	2,099,997	0.0000 %
fecha_def	2,082,438	2,099,997	99.1639 %
intubado	0	2,099,997	0.0000 %
neumonia	0	2,099,997	0.0000 %
edad	0	2,099,997	0.0000 %
nacionalidad	0	2,099,997	0.0000 %
embarazo	0	2,099,997	0.0000 %
habla_lengua_indig	0	2,099,997	0.0000 %
indigena	0	2,099,997	0.0000 %
diabetes	0	2,099,997	0.0000 %
epoc	0	2,099,997	0.0000 %
asma	0	2,099,997	0.0000 %
inmusupr	0	2,099,997	0.0000 %
hipertension	0	2,099,997	0.0000 %
otra_com	0	2,099,997	0.0000 %
cardiovascular	0	2,099,997	0.0000 %
obesidad	0	2,099,997	0.0000 %
renal_cronica	0	2,099,997	0.0000 %
tabaquismo	0	2,099,997	0.0000 %
otro_caso	0	2,099,997	0.0000 %
toma_muestra_lab	0	2,099,997	0.0000 %
resultado_lab	0	2,099,997	0.0000 %
toma_muestra_antigeno	0	2,099,997	0.0000 %
resultado_antigeno	0	2,099,997	0.0000 %
clasificacion_final	0	2,099,997	0.0000 %
fecha_resultado	2,082,281	2,099,997	99.1564 %
migrante	0	2,099,997	0.0000 %
pais_nacionalidad	0	2,099,997	0.0000 %
pais_origen	0	2,099,997	0.0000 %
uci	0	2,099,997	0.0000 %
anio_fuente	0	2,099,997	0.0000 %
archivo_fuente	0	2,099,997	0.0000 %

Interpretación: los NULL de MUNICIPIO_UM y CLUES son estructurales porque esas variables no existen en 2022. FECHA_RESULTADO combina 1,999,998 NULL estructurales de 2022 con 82,283 centinelas convertidos en 2023. FECHA_DEF concentra 2,082,438 NULL derivados de los centinelas de ambos años. En el resto de las columnas auditadas no se observaron NULL.

Calidad_de_datos					
WITH conteos AS (SELECT Enter a SQL expression to filter results (use Ctrl+Spa					
	A-Z columna	123 nulos	123 total	123 porcentaje_nulos	
1	fecha_def	2,082,438	2,099,997	99.1639	
2	fecha_resultado	2,082,281	2,099,997	99.1564	
3	dues	1,999,998	2,099,997	95.2381	
4	municipio_um	1,999,998	2,099,997	95.2381	
5	año_fuente	0	2,099,997	0	
6	archivo_fuente	0	2,099,997	0	
7	asma	0	2,099,997	0	
8	cardiovascular	0	2,099,997	0	
9	clasificacion_final	0	2,099,997	0	
10	diabetes	0	2,099,997	0	
11	edad	0	2,099,997	0	
12	embarazo	0	2,099,997	0	
13	entidad_nac	0	2,099,997	0	
14	entidad_res	0	2,099,997	0	
15	entidad_um	0	2,099,997	0	
16	epoc	0	2,099,997	0	
17	fecha_actualizacion	0	2,099,997	0	
18	fecha_ingreso	0	2,099,997	0	
19	fecha_sintomas	0	2,099,997	0	
20	habla_lengua_indig	0	2,099,997	0	
21	hipertension	0	2,099,997	0	
22	id_registro	0	2,099,997	0	
23	indigena	0	2,099,997	0	
24	inmigrantes	0	2,099,997	0	
25	intubado	0	2,099,997	0	
26	localidad_res	0	2,099,997	0	
27	migrantes	0	2,099,997	0	
28	municipio_res	0	2,099,997	0	
29	nacionalidad	0	2,099,997	0	
30	neumonia	0	2,099,997	0	
31	obesidad	0	2,099,997	0	
32	origen	0	2,099,997	0	
33	otra_com	0	2,099,997	0	
34	otra_caso	0	2,099,997	0	
35	pais_nacionalidad	0	2,099,997	0	
36	pais_origen	0	2,099,997	0	
37	renal_cronica	0	2,099,997	0	
38	resultado_antigeno	0	2,099,997	0	
39	resultado_lab	0	2,099,997	0	
40	sector	0	2,099,997	0	
41	sexo	0	2,099,997	0	
42	tabaquismo	0	2,099,997	0	
43	tipo_paciente	0	2,099,997	0	
44	toma_muestra_antigeno	0	2,099,997	0	
45	toma_muestra_lab	0	2,099,997	0	
46	uid	0	2,099,997	0	

Perfil completo de valores NULL ordenado por porcentaje.

Resultados de calidad

La siguiente tabla resume los problemas de calidad e ingesta detectados, la regla aplicada y el resultado final. Este apartado concentra los hallazgos solicitados en el entregable: errores de ingesta, valores faltantes, anomalías, duplicados y decisiones de limpieza.

ID	Problema	Evidencia	Decisión / solución	Verificación
DQ-001	Duplicación física completa de 2022	Dos mitades con SHA-256 idénticos	Generar copia WORKING reproducible; RAW intacto	1,999,998 registros útiles, 41 columnas, 0 filas malformadas
DQ-002	Evolución 41 -> 44 columnas	2023 agrega MUNICIPIO_UM, CLUES y FECHA_RESULTADO	STAGE y TYPED por versión; homologación explícita	Consolidación sin desplazamiento de campos
DQ-003	9999-99-99 en fechas	Centinela no convertible a DATE	CASE -> NULL en TYPED	Conteos NULL coinciden con centinelas
DQ-004	<TAB>99 en MIGRANTE	Carácter de control en ID 15ec76	BTRIM antes de SMALLINT	Valor tipado = 99; original conservado
ING-001	psql en WIN1252	client_encoding incompatible con script UTF-8	\encoding UTF8	COPY 1999998 y COPY 99999
DQ-005	NULL estructural 2022	Variables exclusivas de 2023	NULL tipado durante homologación	Trazabilidad mediante anio_fuente / archivo_fuente
Duplicados	Posibles repeticiones históricas	Auditoría por ID y fecha	No se aplicó eliminación	0 ID repetidos y 0 duplicados exactos
Códigos especiales	97/98/99/999	Valores definidos en catálogos	Conservar e interpretar por dominio	No se trataron como errores por defecto

Validación final de controles

El script 08_validacion_final.sql no modifica datos; concentra controles de entorno, conteos por capa, conciliación, unicidad, NULL principales, trazabilidad por año, nacionalidad y caso MIGRANTE. Todos los controles críticos terminaron en estado OK.

	A-Z prueba	A-Z resultado	A-Z esperado	A-Z estado
1	STAGE 2022	1999998	1999998	OK
2	TIPADA 2022	1999998	1999998	OK
3	STAGE 2023	99999	99999	OK
4	TIPADA 2023	99999	99999	OK
5	HISTORICA	2099997	2099997	OK
6	ID NULL	0	0	OK
7	ID REPETIDOS	0	0	OK
8	INCONSISTENCIA NACIONALIDAD	0	0	OK

Validación final con todos los controles en estado OK.

Conclusiones

La práctica permitió comprobar que la calidad de un proceso de minería de datos depende de decisiones tomadas desde la ingesta. La separación RAW -> WORKING -> STAGE -> TYPED -> HISTÓRICA evitó ocultar anomalías y permitió conservar evidencia de cada transformación. El centinela 9999-99-99, el carácter de tabulación en MIGRANTE y el cambio de 41 a 44 columnas son ejemplos de problemas que podrían propagarse a etapas posteriores si se cargaran los datos directamente a un esquema rígido sin inspección previa.

El principal resultado técnico fue una tabla histórica homologada con 2,099,997 registros, exactamente igual a la suma de los registros válidos de 2022 y 2023. No se perdieron filas durante el tipado, no se detectaron ID_REGISTRO nulos o repetidos y no fue necesario eliminar duplicados. Las variables de fecha se transformaron de forma explícita, mientras que los códigos 97, 98, 99 y 999 se conservaron cuando el catálogo les asignaba un significado válido.

En el análisis exploratorio se observó que PAIS_NACIONALIDAD presenta 152 valores distintos y que México concentra 98.7057 % de los registros. Para la dimensión territorial se confirmó que MUNICIPIO_RES debe interpretarse junto con ENTIDAD_RES; se identificaron 2,369 combinaciones entidad-municipio y los casos con código 999 se interpretaron como NO ESPECIFICADO, no como errores. La auditoría de NULL distinguió entre ausencia semántica derivada de centinelas y ausencia estructural causada por la evolución del esquema.

Como limitaciones, los dos periodos tienen tamaños muy diferentes y la fuente 2022 llegó físicamente duplicada, por lo que fue necesario generar una copia de trabajo reproducible. Además, el descriptor proporcionado no refleja por completo el esquema real de 2023, de modo que los CSV reales y los catálogos debieron contrastarse antes de definir los tipos. Estas condiciones refuerzan la necesidad de versionar fuentes, reglas de transformación y controles de calidad antes de utilizar los datos en modelado o visualización.

Reproducibilidad y orden de ejecución

Orden	Archivo	Función
1	scripts/inspeccionar_fuentes.py	Tamaño, codificación, delimitadores y encabezados.
2	scripts/preparar_2022.py	Genera la copia WORKING 2022.
3	scripts/perfilar_fuentes.py	Perfilado estructural y generación de manifest / inspección.
4	sql/postgresql/00_database.sql	Crea covid20a23sedi.
5	sql/postgresql/01_stage.sql	Crea las tablas STAGE.
6	sql/postgresql/02_ingesta.sql	Carga mediante psql / \copy.
7	sql/postgresql/03_perfilado.sql	Valida fechas, numéricos, longitudes y caracteres de control.
8	sql/postgresql/04_tabla_tipada.sql	Construye TYPED y aplica transformaciones justificadas.
9	sql/postgresql/05_consolidacion.sql	Consolida periodos y audita duplicados.
10	sql/postgresql/06_calidad.sql	Calcula NULL y porcentajes de todas las columnas.
11	sql/postgresql/07_eda.sql	EDA de nacionalidad, municipio y códigos especiales.
12	sql/postgresql/08_validacion_final.sql	Control integral final.

POR SEGURIDAD: El repositorio y el ZIP no contienen contraseñas, llaves ni credenciales. Las rutas locales del script de ingesta deben ajustarse al entorno donde se reproduzca el proceso.

Fuentes de referencia proporcionadas

- Práctica 2 DM - Ingesta limpieza y EDA.pdf. Guía oficial de la práctica.
- 201128 Catalogos.xlsx / 201128 Catalogos.pdf. Catálogos oficiales utilizados para interpretar códigos.
- 201128 Descriptores.xlsx / 201128 Descriptores.pdf. Descriptor de variables proporcionado.
- Archivos muestra200k_COVID19MEXICOLOC2022.csv y muestra100k_COVID19MEXICOLOC2023.csv. Fuentes de datos analizadas.
- Repositorio GitHub Equipo 13: <https://github.com/YarielNavarreteFlores/mineria-datos-equipo13>